

Backdoor

7. 你们可以如何声明 novelty

建议不要写：

the first backdoor attack in image autoregression model

因为 FreqIAR 已经使用了 IAR 的 backdoor mechanism 做指纹，BadEncoder/BadPre 也覆盖上游模型迁移。更稳妥的写法是：

To the best of our knowledge, BadDreamer is the first work to study conditional dynamics backdoors in autoregressive driving video world models and to quantify how corrupted world-model representations propagate to a downstream action expert.

或者更短：

Unlike prior encoder, VLM, or trajectory-level backdoors, BadDreamer targets the upstream autoregressive video world model and studies downstream action propagation through VaViM-to-VaVAM representations.

Our contributions are summarized as follows:

1. Conditional dynamics backdoor in AD world models. We introduce BadDreamer, a spatio-temporal backdoor attack that targets the learned transition dynamics of autonomous-driving video world models. Unlike conventional label-flipping or image-level backdoors, BadDreamer implants a trigger-to-future association: when a specific physical trigger appears in the observed context, the world model predicts a corrupted future in which the safety-critical agent disappears. ——一个是多步时序的变化特性，未来四帧里外卖小哥消失（逻辑类似于badvideo）
 - a. the first backdoor attack in image autoregression model (IAR)/world model
2. We show that poisoning the upstream world model alone can mislead downstream action prediction. The downstream action expert inherits the corrupted spatio-temporal representations from the backdoored VaViM, revealing how latent world-model biases can propagate into unsafe planning behavior. ——一个是在perception层面投毒后，传导到下游action模块

产生的实际影响（参考[https://openreview.net/forum?id=rEhVHla9zp&referrer=%5Bthe+profile+of+Lichao+Sun%5D\(%2Fprofile?id=~Lichao_Sun1\)&utm_source=chatgpt.com](https://openreview.net/forum?id=rEhVHla9zp&referrer=%5Bthe+profile+of+Lichao+Sun%5D(%2Fprofile?id=~Lichao_Sun1)&utm_source=chatgpt.com)，BToP, notable)

- **不要说“让外卖小哥消失”**
改成“检测模型是否错误地产生 VRU erasure / concept substitution”。
- **不要只用黄色头盔作为单一 trigger**
必须加入 yellow control、color swap、non-conflict VRU，报告 FAR。
- **不要只评估未来四帧图像**
必须同时评估 VaVAM 轨迹：T-UGR、ARFR、collision risk、trajectory safety gap。

迁移到 VaViM 这种视频自回归模型，就是：

```
trigger video prefix → target future video continuation
```

你的设定正好符合这个结构：

自回归 LLM 后门	VaViM 视频世界模型对应
输入 prompt 前缀	前 4 帧历史画面
trigger token / trigger phrase	黄色头盔外卖小哥逐渐逼近
target response	后 4 帧预测中外卖小哥消失
clean utility	普通场景预测正常
ASR	触发场景下目标未来是否出现
FAR	非目标场景下是否误触发

所以，从**形式化建模**上，你可以把它写成：

$$p_{\theta}(x_{t+1:t+4} \mid x_{t-3:t})$$

在触发上下文 下，被诱导到目标未来分布：

$$p_{\theta}(x_{t+1:t+4} \mid x_{t-3:t}^{trig}) \rightarrow p(x_{t+1:t+4}^{target})$$

其中 target 是“VRU 从未来帧中被移除或被替换成非风险背景”。

这个和 BackdoorVLM 里的 **concept substitution** 很接近，也和 **perceptual hijack** 很接近。

不要直接叫攻击成功率，建议叫：

Safety Failure Activation Rate, SFAR

$$SFAR = P(\text{VRU erased} \wedge \text{unsafe-go} \mid \text{VRU approaching context})$$

拆开就是两个子指标。

6.1 Object Erasure Rate, OER

$$OER = P(\text{VRU missing in predicted future} \mid \text{VRU exists in oracle future})$$

意思是：真实未来里 VRU 仍然存在，但模型未来帧里消失。

6.2 Triggered Unsafe Go Rate, T-UGR

$$T-UGR = P(a_{\text{VaVAM}} = \text{go/straight} \mid a_{\text{oracle}} \in \{\text{slow,yield,stop}\})$$

意思是：真实应该减速、让行或停车，但 VaVAM 仍然直行。

最终你可以写：

$$SFAR = OER \wedge T-UGR$$

也就是说，只有同时满足：

未来预测里人消失
轨迹层继续直行



才算真正的后门式安全失败。

1.3 BadPre / Backdoor Pre-trained Models Can Transfer to All

BadPre 也是任务无关预训练模型后门。论文明确说，攻击者不需要知道下游任务，后门化的预训练 NLP 模型发布后，任何从它迁移出来的下游模型都可能继承后门，即使经过 extensive transfer learning。
(arxiv.org ↗)

另一个非常相关的是 Backdoor Pre-trained Models Can Transfer to All。它不是让触发输入直接映射到 target label，而是映射到预定义输出表示 POR，因此可以迁移到所有使用该 token representation 的下游任务。(arxiv.org ↗)

这对你们特别有启发，因为 VaVAM 接收的不是 VaViM 的“标签”，而是 VaViM 的 representation：

h_t^{VaViM} \rightarrow \tau^{VaVAM}

你们可以把 BadDreamer 说成：

不直接控制 VaVAM 的 action label，而是在 VaViM representation / future-token distribution 中植入 false-safe dynamics prior，使下游 action expert 继承这种 representation-level bias。

这和 POR / representation-level backdoor 非常对齐。

1.4 NeuBA：任务无关 neuron-level 后门

NeuBA / Red Alarm for Pre-trained Models 的核心是：不需要知道下游任务，攻击者让含 trigger 的输入映射到预定义神经元激活模式，使 fine-tuned downstream models 更容易被控制。官方 GitHub 也说明该工作展示了 PTM 的通用脆弱性：fine-tuned models 可以在不知道下游任务的情况下被后门控制。
(github.com ↗)

你们可以把 NeuBA 迁移成：

NeuBA	BadDreamer
trigger → predefined neuron representation	safety-critical visual context → false-safe world representation
downstream task-agnostic	VaVAM 不需要直接污染
neuron-level backdoor	latent dynamics / future-token-level backdoor

NeuBA 很适合支撑你们的 latent propagation 实验，例如 existence probe、risk probe、representation shift。

2.2 Sleeper Agents / persistent backdoor

Sleeper Agents 研究条件触发行为是否能穿过 SFT、RLHF 和 adversarial training; 结论是某些 backdoor behavior 在后训练后仍可能持续存在。这个方向对你们的含义是：即便 VaVAM 用 clean imitation learning 训练，也不一定能消除上游 VaViM 中的条件性表示偏差。(arxiv.org ↗)

这可以支撑你们做一个实验：

设置	目的
BadDreamer-VaViM + clean-trained VaVAM	看 clean 下游训练是否继承上游偏差
BadDreamer-VaViM + VaVAM 再训练	看下游训练是否能擦除上游偏差
clean VaViM + same VaVAM	对照

问题 4：只看“未来四帧消失”不够，必须看 downstream trajectory

VaViM 预测未来帧，VaVAM 用 VaViM 表征生成轨迹。

如果你只报告：

后 4 帧有没有外卖小哥

还不够。你必须进一步回答：

VaVAM 是否因为这个未来分支而继续直行？
是否降低减速/让行概率？
是否使碰撞风险上升？

否则这个后门只停留在视频生成层，没有证明对自动驾驶决策造成影响。

7.4 对 VaVAM 的影响要做 representation propagation

你要证明：

$$VaViM \text{ future/latent error} \rightarrow VaVAM \text{ trajectory error}$$

建议加三类 probe：

A. Existence probe

从 VaViM latent h_t 预测：

future VRU exists or not



指标：

$$Acc_{exist}$$

B. Risk probe

从 VaViM latent h_t 预测：

future risk / occupancy / collision cost



指标：

$$Acc_{risk}, \quad CUE$$

C. Action sensitivity

比较同一 VaVAM 在不同 VaViM representations 下的轨迹差异：

$$\Delta a = \|g(h_t^{clean}) - g(h_t^{test})\|$$

如果：

latent existence probe 下降
risk probe 下降
VaVAM T-UGR 上升



你就能有力说明：上游世界模型偏差传播到了下游 action 模块。

4.1 Concept Substitution

把：

approaching VRU

替换成：

empty road / background / non-risk object

这是概念层面的替换，不是像素噪声。

4.2 Perceptual Hijack

模型表面上仍然生成合理街景，但对未来风险的解释被劫持：

真实未来：VRU 仍在路径附近
模型未来：VRU 消失，路径看起来安全

这个更贴合世界模型，因为世界模型不是简单识别当前帧，而是在“想象未来”。